
PROYECTO FINAL

AUTOENCODERS

LUIS EDUARDO JIMÉNEZ DEL MURO
SANTIAGO MONTES DE OCA
SANTIAGO REYES CASTILLO

CURSO: DEEP LEARNING
PROFESOR: IVÁN REYES AMEZCUA



03/03/2026

CONTENIDO

- OBJETIVO
- JUSTIFICACIÓN
- MARCO TEÓRICO
- METODOLOGÍA
- RESULTADOS
- CONCLUSIÓN

OBJETIVO


- Implementar un modelo de Deep Learning basado en Variational Autoencoders (VAE).
- Generar imágenes sintéticas de motocicletas mediante aprendizaje no supervisado.
- **Dataset:** Caltech-101 (categoría motocicletas) obtenido de Kaggle.
- **Herramientas:** TensorFlow, Keras, Python.

MARCO TEÓRICO

AUTOENCODER TRADICIONAL

Un autoencoder es un modelo que utiliza redes neuronales para la compresión y reconstrucción de información. Tiene tres componentes principales:

- Encoder
- Espacio latente
- Decoder



An introduction to autoencoders (Umberto Michelucci).


Este modelo suele minimizar funciones de pérdida como MSE (mean squared error) pues miden la diferencia entre el pixel de entrada y salida. 4

MARCO TEÓRICO

VARIATIONAL AUTOENCODER

Un VAE (Variational Autoencoder) es una extensión del autoencoder tradicional que está orientada a la generación.

- El encoder estima parámetros μ y σ para una distribución normal en el espacio latente. Esto permite samplear puntos aleatorios del espacio latente para generar nuevas imágenes.



MARCO TEÓRICO

FUNCIÓN DE PÉRDIDA DE UN VAE

- Función de reconstrucción (MSE): mide la similaridad entrada-salida.
- “KL-Divergence” (Kullback Leibler divergence): mide la diferencia entre la distribución latente a una normal estándar.

$$\mathcal{L}_{\text{VAE}} = \underbrace{\frac{1}{mn} \sum_{i=1}^{mn} (x_i - y_i)^2}_{\text{Reconstruction Loss (MSE)}} + \underbrace{\frac{1}{2} \sum_{j=1}^d (1 + \log(\sigma_j^2) - \mu_j^2 - \sigma_j^2)}_{\text{KL Divergence}}$$

MARCO TEÓRICO

B-AUTO ENCODER

El parámetro β regula el trade-off entre reconstrucción y regularización del espacio latente.

- **β bajo:** Prioriza reconstrucción, pero mayor entrelazamiento de características.
- **β alto:** Mayor separación de características, pero menor calidad de reconstrucción.

$$\text{Total Loss} = \text{Reconstruction Loss} + \beta \times \text{KL Divergence}$$

METODOLOGÍA

PREPROCESAMIENTO

Exploración y preprocesamiento de datos:

- Tres resoluciones evaluadas: (100×100), (128×128), (256×256) pixeles.
- Resolución final seleccionada: (128×128). Mejor relación calidad/complejidad.
- Normalización: División entre 255 (rango [0,1]).

División de datos:

- Entrenamiento: 64%
- Validación: 16% (20% del conjunto de entrenamiento)
- Prueba: 20%

ARQUITECTURA DEL MODELO

ENCODER

Entrada: Imágenes 128x128x3

Capas convolucionales:

- Conv2D (32 filtros) $\rightarrow$ 64x64
- Conv2D (64 filtros) $\rightarrow$ 32x32
- Conv2D (128 filtros) $\rightarrow$ 16x16
- Conv2D (256 filtros) $\rightarrow$ 8x8
- Conv2D (512 filtros) $\rightarrow$ 4x4
- Conv2D (1028 filtros) $\rightarrow$ 2x2

Cada capa incluye:

- Batch Normalization + ReLU



Espacio latente: 28
dimensiones



$$z = \mu + \sigma \underline{\epsilon}$$

ARQUITECTURA DEL MODELO

DECODER


Proceso inverso al encoder mediante **Conv2DTranspose**.

Capas convolucionales:

- $2 \times 2 \rightarrow 4 \times 4$ (1028 filtros)
- $4 \times 4 \rightarrow 8 \times 8$ (512 filtros)
- $8 \times 8 \rightarrow 16 \times 16$ (256 filtros)
- $16 \times 16 \rightarrow 32 \times 32$ (128 filtros)
- $32 \times 32 \rightarrow 64 \times 64$ (64 filtros)
- $64 \times 64 \rightarrow 128 \times 128 \times 3$ (32 filtros)




Cada capa incluye:

- Batch Normalization + ReLU






ENTRENAMIENTO

MODELO INICIAL



ENTRENAMIENTO

MODELO FINAL



RESULTADOS DEL ENTRENAMIENTO

Métrica	Modelo Inicial	Modelo Final	Mejora
Pérdida de Reconstrucción	~2,000	~1,000	50%
KL-Divergence	~500	~40	92%
Pérdida total	~2,500	~1,040	60%

RESULTADOS

IMAGENES NUNCA OBSERVADAS

Top: Original | Bottom: Reconstructed



More Detailed

More Detailed

Blurry


More Detailed

Blurry

RESULTADOS

GENERACION DE NUEVAS IMAGENES

Generated Images (n=10)



LIMITACIONES

- 1 Ausencia de color: MSE promedia colores → tonos grisáceos.
- 2 Desenfoque: Inherente a la naturaleza de los VAE (Liu, 2024)
- 3 Trade-off reconstrucción-regularización:
Estabilizar una pérdida desestabiliza la otra.

CONCLUSIONES

- 1 Se logró implementar exitosamente un β -VAE funcional.
- 2 Reducción significativa de pérdidas vs. modelo inicial (60% pérdida total).
- 3 El modelo aprendió características distintivas de motocicletas.
- 4 Las limitaciones son conocidas en la literatura de VAEs.
- 5 Explorar otros tipos de VAE (Conditional VAE, VQ VAE, etc).

REFERENCIAS

- Liu, J. (2025). Research on the application of variational autoencoder in image generation. ITM Web of Conferences, 70, 02001. <https://doi.org/10.1051/itmconf/20257002001>
- Newson, A. (n.d.). Autoencoders and generative models [Course materials]. MVA - DELIRES, Telecom Paris. Retrieved from https://perso.telecom-paristech.fr/anewson/doc/courses/mva/mva_generative_models.pdf
- Michelucci, U. (2022, January 12). An introduction to autoencoders. arXiv preprint arXiv:2201.03898. <https://arxiv.org/pdf/2201.03898>
- Higgins, I., Matthey, L., Pal, A., Burgess, C., Glorot, X., Botvinick, M., Mohamed, S., & Lerchner, A. (2017). β -VAE: Learning basic visual concepts with a constrained variational framework. In Proceedings of the International Conference on Learning Representations. <https://www.cs.toronto.edu/~bonner/courses/2022s/csc2547/papers>
- Dataset obtenido de: <https://www.kaggle.com/datasets/imbikramsaha/caltech-101?resource=download>