
PROYECTO FINAL

AUTOENCODERS

LUIS EDUARDO JIMÉNEZ DEL MURO
SANTIAGO MONTES DE OCA
SANTIAGO REYES CASTILLO

CURSO: DEEP LEARNING
PROFESOR: IVÁN REYES AMEZCUA



03/03/2026

CONTENIDO

- OBJETIVO
- MARCO TEÓRICO
- METODOLOGÍA
- ARQUITECTURA DEL MODELO
- ENTRENAMIENTO
- RESULTADOS
- LIMITACIONES
- CONCLUSIÓN
- REFERENCIAS

OBJETIVO


- Implementar un modelo de Deep Learning basado en Variational Autoencoders (VAE).
- Generar imágenes sintéticas de motocicletas mediante aprendizaje no supervisado.
- **Dataset:** Caltech-101 (categoría motocicletas) obtenido de Kaggle.
- **Herramientas:** TensorFlow, Keras, Python.

MARCO TEÓRICO

AUTOENCODER TRADICIONAL

Un autoencoder es un modelo que utiliza redes neuronales para la compresión y reconstrucción de información. Tiene tres componentes principales:

- Encoder
- Espacio latente
- Decoder



An introduction to autoencoders (Umberto Michelucci).


Este modelo suele minimizar funciones de pérdida como MSE (mean squared error) pues miden la diferencia entre el pixel de entrada y salida. 4

MARCO TEÓRICO

VARIATIONAL AUTOENCODER

Un VAE (Variational Autoencoder) es una extensión del autoencoder tradicional que está orientada a la generación.

- El encoder estima parámetros μ y σ para una distribución normal en el espacio latente. Esto permite samplear puntos aleatorios del espacio latente para generar nuevas imágenes.



Variational Autoencoders in Practice (Alasdair Newson)

MARCO TEÓRICO

FUNCIÓN DE PÉRDIDA DE UN VAE

- Función de reconstrucción (MSE): mide la similaridad entrada-salida.
- “KL-Divergence” (Kullback Leibler divergence): mide la diferencia entre la distribución latente a una normal estándar.

$$\mathcal{L}_{\text{VAE}} = \underbrace{\frac{1}{mn} \sum_{i=1}^{mn} (x_i - y_i)^2}_{\text{Reconstruction Loss (MSE)}} + \underbrace{\frac{1}{2} \sum_{j=1}^d (1 + \log(\sigma_j^2) - \mu_j^2 - \sigma_j^2)}_{\text{KL Divergence}}$$

MARCO TEÓRICO

B-AUTO ENCODER

El parámetro β regula el trade-off entre reconstrucción y regularización del espacio latente.

- **β bajo:** Prioriza reconstrucción, pero mayor entrelazamiento de características.
- **β alto:** Mayor separación de características, pero menor calidad de reconstrucción.

$$\text{Total Loss} = \text{Reconstruction Loss} + \beta \times \text{KL Divergence}$$

METODOLOGÍA

PREPROCESAMIENTO

Exploración y preprocesamiento de datos:

- Tres resoluciones evaluadas: (100×100), (128×128), (256×256) pixeles.
- Resolución final seleccionada: (128×128). Mejor relación calidad/complejidad.
- Normalización: División entre 255 (rango [0,1]).

División de datos:

- Entrenamiento: 64%
- Validación: 16% (20% del conjunto de entrenamiento)
- Prueba: 20%

ARQUITECTURA DEL MODELO

ENCODER

Entrada: Imágenes 128x128x3

Capas convolucionales:

- Conv2D (32 filtros) $\rightarrow$ 64x64
- Conv2D (64 filtros) $\rightarrow$ 32x32
- Conv2D (128 filtros) $\rightarrow$ 16x16
- Conv2D (256 filtros) $\rightarrow$ 8x8
- Conv2D (512 filtros) $\rightarrow$ 4x4
- Conv2D (1028 filtros) $\rightarrow$ 2x2

Cada capa incluye:

- Batch Normalization + ReLU



Espacio latente: 28
dimensiones



$$z = \mu + \sigma \underline{\epsilon}$$

ARQUITECTURA DEL MODELO

DECODER


Proceso inverso al encoder mediante **Conv2DTranspose**.

Capas convolucionales:

- $2 \times 2 \rightarrow 4 \times 4$ (1028 filtros)
- $4 \times 4 \rightarrow 8 \times 8$ (512 filtros)
- $8 \times 8 \rightarrow 16 \times 16$ (256 filtros)
- $16 \times 16 \rightarrow 32 \times 32$ (128 filtros)
- $32 \times 32 \rightarrow 64 \times 64$ (64 filtros)
- $64 \times 64 \rightarrow 128 \times 128 \times 3$ (32 filtros)




Cada capa incluye:

- Batch Normalization + ReLU






ENTRENAMIENTO

MODELO INICIAL



ENTRENAMIENTO

MODELO FINAL



RESULTADOS DEL ENTRENAMIENTO

Métrica	Modelo Inicial	Modelo Final	Mejora
Pérdida de Reconstrucción	~2,000	~1,000	50%
KL-Divergence	~500	~40	92%
Pérdida total	~2,500	~1,040	60%

RESULTADOS

IMAGENES NUNCA OBSERVADAS

Top: Original | Bottom: Reconstructed



More Detailed

More Detailed

Blurry


More Detailed

Blurry

RESULTADOS

GENERACION DE NUEVAS IMAGENES

Generated Images (n=10)



LIMITACIONES

- 1 Ausencia de color: MSE promedia colores → tonos grisáceos.
- 2 Desenfoque: Inherente a la naturaleza de los VAE (Liu, 2024)
- 3 Trade-off reconstrucción-regularización:
Estabilizar una pérdida desestabiliza la otra.

CONCLUSIONES

- 1 Se logró implementar exitosamente un β -VAE funcional.
- 2 Reducción significativa de pérdidas vs. modelo inicial (60% pérdida total).
- 3 El modelo aprendió características distintivas de motocicletas.
- 4 Las limitaciones son conocidas en la literatura de VAEs.
- 5 Explorar otros tipos de VAE (Conditional VAE, VQ VAE, etc).

REFERENCIAS

- Liu, J. (2025). Research on the application of variational autoencoder in image generation. ITM Web of Conferences, 70, 02001.<https://doi.org/10.1051/itmconf/20257002001>
- Newson, A. (n.d.). Autoencoders and generative models [Course materials]. MVA - DELIRES, Telecom Paris. Retrieved from https://perso.telecom-paristech.fr/anewson/doc/courses/mva/mva_generative_models.pdf
- Michelucci, U. (2022, January 12). An introduction to autoencoders. arXiv preprint arXiv:2201.03898. <https://arxiv.org/pdf/2201.03898>
- Higgins, I., Matthey, L., Pal, A., Burgess, C., Glorot, X., Botvinick, M., Mohamed, S., & Lerchner, A. (2017). β -VAE: Learning basic visual concepts with a constrained variational framework. In Proceedings of the International Conference on Learning Representations.
<https://www.cs.toronto.edu/~bonner/courses/2022s/csc2547/papers>
- Dataset obtenido de: <https://www.kaggle.com/datasets/imbikramsaha/caltech-101?resource=download>